

Model Heterokedastisitas Data Deret Waktu
Generalized Autoregressive Conditional Heteroskedasticity
(GARCH)

Studi Kasus:
Return Saham ACES Periode 1 Agustus 2018 – 31 Januari 2019

Tugas Akhir Semester
Analisis Deret Waktu
(STK 553)

Oleh:

Husnul Finisa	G152180111
Agnes Maludfi Putri	G152180171
Putri Maulidina Fadilah	G152180231
Rizqi Haryastuti	G152180251



SEKOLAH PASCASARJANA
INSTITUT PERTANIAN BOGOR
BOGOR
2019

LANDASAN TEORI

Data Deret Waktu

Data deret waktu merupakan data yang terdiri atas satu objek dan meliputi beberapa periode waktu, yaitu harian, mingguan, bulanan, tahunan dll. Menganalisis data yang berorientasi waktu merupakan salah satu masalah yang paling penting yang banyak dihadapi pada bidang keuangan.

Heteroskedastisitas

Heteroskedastisitas adalah adanya varians error yang tidak konstan dalam data deret waktu. Untuk mengatasi hal ini, model yang dapat digunakan yaitu, Model *Autoregressive Conditional Heteroskedasticity* (ARCH) atau Model *Generalized Autoregressive Conditional Heteroskedasticity* (GARCH).

Model *Generalized Autoregressive Conditional Heteroskedasticity* (GARCH)

Model *Generalized Autoregressive Conditional Heteroskedasticity* (GARCH) merupakan pengembangan dari model ARCH yang dikemukakan oleh Bollerslev (1986). Model GARCH merupakan salah satu model yang dapat digunakan untuk menggambarkan sifat dinamik fungsi volatilitas, yakni jika terjadi variabilitas data yang relatif tinggi pada suatu waktu, kecenderungan yang sama dalam kurun waktu selanjutnya akan terjadi dan sebaliknya. Hali ini juga sering disebut kasus variansi yang bervariasi waktu yang merupakan satu keadaan yang disebut heteroskedastisitas. Model GARCH memiliki ordo (p,q) yang secara umum dinyatakan sebagai berikut:

$$y_t = C + \varepsilon_t$$
$$\sigma_t^2 = \omega + \beta\sigma_{t-1}^2 + \alpha\varepsilon_{t-1}^2$$

METODOLOGI PENELITIAN

Data

Tugas ini akan menggunakan data deret waktu berupa *return* dari *adjusted close price* saham ACES (PT Ace Hardware Indonesia Tbk) pada periode 1 Agustus 2018 hingga 31 Januari 2019 yang berasal dari laman *Yahoo! Finance* dan diunduh dengan perangkat R.

Prosedur Analisis

Berikut adalah tahapan analisis data deret waktu dengan model GARCH pada studi kasus ini yang dibagi menjadi tiga bagian utama.

Bagian pertama adalah penyediaan data deret waktu yang menggunakan perangkat R. Mengunduh data saham, *adjusted close price* dari situs Yahoo menggunakan *quantmod* dengan rincian sebagai berikut:

1. Inisialisasi simbol saham yang akan diunduh.
2. Deklarasi rentang waktu saham, yakni mulai 1 Agustus hingga 31 Desember 2018.
3. Menyimpan data yang telah diunduh dalam format *xts*.
4. Melakukan inisialisasi terhadap data saham yang hilang (bernilai NA) dengan rata-rata dari saham itu sendiri.

Bagian kedua adalah eksplorasi terhadap data deret waktu, yakni saham yang akan dianalisis. Tahapan dalam bagian ini dapat dilakukan dengan menggunakan perangkat apapun karena tahapan analisis berlaku secara umum.

1. Melakukan eksplorasi secara visual dengan plot data deret waktu, yakni *adjusted close price* saham.
2. Melakukan transformasi data saham, *adjusted close price* menjadi data *return*. Hal ini dilakukan karena dalam beberapa literatur dan studi kasus yang ditemukan, fokus analisis GARCH adalah pada data *return* yang telah stasioner.

$$return = \log \left(\frac{y_t}{y_{t-1}} \right)$$

3. Melakukan eksplorasi secara visual terhadap *return* dengan plot data deret waktu.

Bagian ketiga adalah tahapan yang utama yaitu analisis data deret waktu yang mengandung heteroskedastisitas jangka panjang (*long term*) dengan model GARCH. Tahapan dalam bagian ini dapat dilakukan dengan menggunakan perangkat apapun.

1. Melakukan pemodelan fungsi rata-rata (*mean*) terhadap data *return*.
Sebelum mengamati bentuk GARCH untuk memodelkan volatilitas data, akan ditentukan bentuk model runtun waktu untuk rata-rata sebagai identifikasi awal. Fungsi rata-rata dapat berupa model regresi, AR, MA, ARMA, ARIMA, atau konstanta, dan lain sebagainya. Jika pada identifikasi plot ACF dan PACF tidak didapatkan *bar* yang keluar pada lag tertentu (tidak ada autokorelasi pada lag tertentu), maka digunakan model kondisional, $y_t = C + \varepsilon_t$, dimana harga data deret waktu merupakan proses *white noise* itu sendiri dan ditambah satu konstanta.

Langkah-langkahnya sebagai berikut:

- i. Membuat plot autokorelasi dan autokorelasi parsial dari data *return*.
 - ii. Identifikasi model tentatif berdasarkan plot ACF dan PACF.
 - iii. Memilih model terbaik berdasarkan AIC terkecil.
 - iv. Menguji sisaan dari model yang telah ditentukan, yang difokuskan pada autokorelasi sisaan.
2. Membuat plot autokorelasi dari komponen sisaan kuadrat untuk mendeteksi adanya korelasi ragam dari *return*. Selain plot, dapat dilihat juga nilai Q Ljung-Box pada tingkat uji 5%. Jika kuadrat sisaan yang signifikan hanya pada lag-lag awal saja, katakanlah 4 lag pertama, maka model yang sesuai adalah ARCH (*short memory*). Namun jika signifikan sampai lag yang panjang, maka model yang sesuai adalah GARCH.
 3. Pendugaan model GARCH. Umumnya pendugaan model ini diawali dengan GARCH(1,1) dan dapat dilakukan *overestimate* pada ordo (p,q) yang lebih tinggi. Pendugaan model akan berhenti saat mulai didapatkan koefisien parameter yang tidak signifikan masuk model. Pada tahap ini juga dapat dilakukan pemodelan dengan atau tanpa konstanta (pada model rata-rata).
 4. Pengujian diagnostik terhadap sisaan model GARCH. Beberapa uji tersebut adalah:
 - i. Uji ARCH LM. Uji ini digunakan untuk melihat apakah masih ada efek ARCH yang tersisa dalam hasil pendugaan model GARCH. H_0 : tidak terdapat efek ARCH/ GARCH dalam residual sampai lag ke- m .
 - ii. Uji korelasi serial. Tahap ini merupakan pengujian uji korelasi serial dari sisaan kuadrat sampai lag ke- m dengan statistik Q Ljung-Box yang dibandingkan dengan kuantil dari sebaran χ_m^2 . H_0 : tidak terdapat korelasi serial dalam kuadrat sisaan.
 - iii. Uji normalitas. Uji ini digunakan untuk melihat asumsi normalitas sisaan model terpenuhi atau tidak. Pengujian normalitas dapat dilakukan dengan uji Jarque-Bera, uji nonparametrik Shapiro-Wilk, atau QQ-plot dari sisaan yang telah dibakukan. H_0 : kuadrat sisaan berdistribusi normal.
 5. Pemilihan model terbaik dengan membandingkan statistik kriteria informasi, seperti AIC dan BIC dari beberapa model alternatif. Umumnya model dianggap baik jika memiliki nilai BIC yang kecil.
 6. Prediksi dengan model yang dianggap terbaik.

HASIL DAN PEMBAHASAN

Dengan Perangkat SAS

Disclaimer. Sebelum mengerjakan studi kasus dalam tugas ini menggunakan perangkat R, kami telah mencoba menggunakan perangkat SAS. Namun karena keterbatasan pengetahuan dan tidak ditemukannya sintak program SAS untuk pemodelan ARMA-GARCH di internet (hanya ditemukan AR-GARCH saja) dan eksplorasi lainnya, kami menggunakan R untuk analisis selengkapannya.

Eksplorasi Data

1. Input data saham dalam R

```
proc import out=aces  
datafile="D:\MATKUL S2 2018\semester 2\ADW\Materi pak farit\tugas  
garch\ACES.xlsx"  
dbms=xlsx replace;  
sheet="Sheet1";  
GETNAMES=YES;  
RUN;
```

*data *races* dimasukkan dengan cara yang sama

2. Membuat plot deret waktu terhadap *adjusted close price* dan *return*

```
proc gplot data=aces;  
plot ACES*A;  
plot races*time;  
symbol1 i=join;  
run;
```



Pemodelan Fungsi Rataan (*Mean Model*)

Pada tahap ini, model rata-rata tidak dicari terlebih dahulu menggunakan analisis deret waktu (Box-Jenkins), melainkan langsung mengasumsikan bahwa model hanya melibatkan intersep atau konstanta saja.

1. Pendugaan intersep.

```
proc autoreg data=races;  
model return = /archtest;
```

Generalized Autoregressive Conditional Heteroskedasticity (GARCH)

`run;`

Parameter Estimates					
Variable	DF	Estimate	Standard Error	t Value	Approx Pr > t
Intercept	1	-0.000160	0.002051	-0.08	0.9380

Berdasarkan uji parameter pada model rata-rata, didapatkan nilai p untuk konstanta yang cukup besar yakni 0.9380 sehingga mengindikasikan tidak layak masuk model. Kemudian muncul kecurigaan bahwa model rata-rata tidak hanya terdiri dari *white noise* prosesnya dan ditambahkan konstanta itu saja, melainkan ada bentuk pemodelan lain yang lebih cocok.

2. Pemeriksaan heterokedastisitas pada sisaan kuadrat dengan LM Test.

Tests for ARCH Disturbances Based on OLS Residuals				
Order	Q	Pr > Q	LM	Pr > LM
1	21.3503	<.0001	20.9011	<.0001
2	21.3755	<.0001	25.5367	<.0001
3	21.3823	<.0001	26.6379	<.0001
4	22.3729	0.0002	26.9769	<.0001
5	35.5273	<.0001	36.8087	<.0001
6	42.8173	<.0001	36.8690	<.0001
7	42.8278	<.0001	36.9303	<.0001
8	42.8325	<.0001	37.0474	<.0001
9	42.9839	<.0001	37.9028	<.0001
10	43.2768	<.0001	38.7832	<.0001
11	43.4039	<.0001	39.1644	<.0001
12	43.4812	<.0001	39.2025	<.0001

Pada pemeriksaan sisaan menggunakan LM Test menghasilkan nilai p yang lebih kecil dari 1% hingga lag 12 (*long term*). Hal ini merupakan indikasi bahwa model GARCH lebih cocok dibandingkan model ARCH. Sehingga model yang akan diuji adalah:

- GARCH(1,1)
- GARCH(1,2)
- GARCH(2,1)

Pemodelan Fungsi (*Variance Model*)

1. Membuat model GARCH (1,1).

```
proc autoreg data=aces;  
model ACES = /garch=(p=1,q=1);  
output out=ragam cev=vhat;  
run;
```

Generalized Autoregressive Conditional Heteroskedasticity (GARCH)

Parameter Estimates					
Variable	DF	Estimate	Standard Error	t Value	Approx Pr > t
Intercept	1	0.001227	0.001648	0.74	0.4566
ARCH0	1	0.0000640	0.0000174	3.68	0.0002
ARCH1	1	0.5723	0.1168	4.90	<.0001
GARCH1	1	0.4372	0.0571	7.66	<.0001

Koefisien parameter ARCH dan GARCH data return signifikan pada $\alpha=5\%$. Selanjutnya akan dilakukan overfitting terhadap salah satu ordo atau keduanya hingga didapatkan koefisien yang tidak signifikan.

2. Membuat model GARCH (1,2).

```
proc autoreg data=races;
model return = /garch=(p=1,q=2);
output out=ragam cev=vhat;
run;
```

Parameter Estimates					
Variable	DF	Estimate	Standard Error	t Value	Approx Pr > t
Intercept	1	0.002243	0.001767	1.27	0.2044
ARCH0	1	0.000235	0.0000192	12.24	<.0001
ARCH1	1	0.6794	0.1193	5.70	<.0001
ARCH2	1	0.003697	0.0808	0.05	0.9635
GARCH1	1	-2.05E-11	0	-Infy	<.0001

Pada output GARCH (1,2), koefisien suku ARCH pada lag ke-2 adalah tidak signifikan masuk model. Maka dapat dikatakan model GARCH (1,2) tidak sesuai.

3. Membuat model GARCH (2,1).

```
proc autoreg data=races;
model return = /garch=(p=2,q=1);
output out=ragam cev=vhat;
run;
```

Parameter Estimates					
Variable	DF	Estimate	Standard Error	t Value	Approx Pr > t
Intercept	1	-0.000154	0.002922	-0.05	0.9580
ARCH0	1	0.000550	0.0421	0.01	0.9896
ARCH1	1	0.000877	0.004954	0.18	0.8594
GARCH1	1	0	56.3937	0.00	1.0000
GARCH2	1	9.9048E-7	68.3273	0.00	1.0000

Dengan meningkatkan ordo p dalam GARCH menjadi 2, didapatkan semua koefisien parameter menjadi tidak signifikan. Maka dapat dikatakan model GARCH (2,1) tidak sesuai.

Note. Pada setiap pemodelan, baik rata-rata maupun ragam, didapatkan konstanta tidak signifikan. Sehingga dicurigai model rata-rata tidak mengandung intersep saja.

Dengan Perangkat R

Eksplorasi Data

1. Menyertakan paket program atau *package*.


```
> library(quantmod)
> library(forecast)
> library(TTR)
> library(graphics)
> library(TSA)
> library(tseries)
> library(fGarch)
```

2. Input data saham dalam R.

```
> aces <- read.csv("D:/Tugas GARCH/ACES.csv",header = T)
> head(aces)
      time      ACES
1 8/1/2018 25.18110
2 8/2/2018 25.44405
3 8/3/2018 25.45199
4 8/6/2018 25.63556
5 8/7/2018 25.70999
6 8/8/2018 25.80921
```

3. Membuat plot deret waktu terhadap *adjusted close price*.

```
> ts.plot(aces$ACES, col="blue", main="Time Series Plot", ylab="Close Price ACES")
```



```
> adf.test(aces$ACES) #p-value = 0.4053 #tidak stasioner

Augmented Dickey-Fuller Test

data: aces$ACES
Dickey-Fuller = -2.4116, Lag order = 5, p-value = 0.4053
alternative hypothesis: stationary
```

Plot deret waktu di atas menggambarkan volatilitas atau besaran perubahan harga yang menunjukkan fluktuasi saham PT Ace Hardware Indonesia Tbk pada 1 Agustus 2018 hingga 31 Januari 2019. Jika dilihat, plot tersebut menampilkan pergerakan yang tidak stasioner, baik dalam ragam maupun rata-rata. Untuk

Generalized Autoregressive Conditional Heteroskedasticity (GARCH)

memastikan kestasioneran data, dilakukan uji ADF. Nilai p sebesar 0.4053 memberi kesimpulan bahwa data tidak stasioner.


4. Menghitung *return*.

Dalam beberapa literatur umumnya digunakan *return* untuk menganalisis data saham. Hal ini disebabkan karena *return* memiliki pergerakan yang cenderung stabil atau stasioner dalam rata-rata sehingga lebih mudah dianalisis.

```
> races <- diff(log(aces$ACES), differences = 1)
> head(races)
[1] 1.038833e-02 3.119299e-04 7.186556e-03 2.898910e-03 3.852006e-03 3.847389e-05
```

5. Membuat plot deret waktu terhadap *return*.

```
> ts.plot(races, col="blue", main="Time Series Plot (Return)", ylab="Return ACES")
```



```
> adf.test(races) #p-value = 0.01 #stationary

Augmented Dickey-Fuller Test

data: races
Dickey-Fuller = -4.517, Lag order = 5, p-value = 0.01
alternative hypothesis: stationary
```

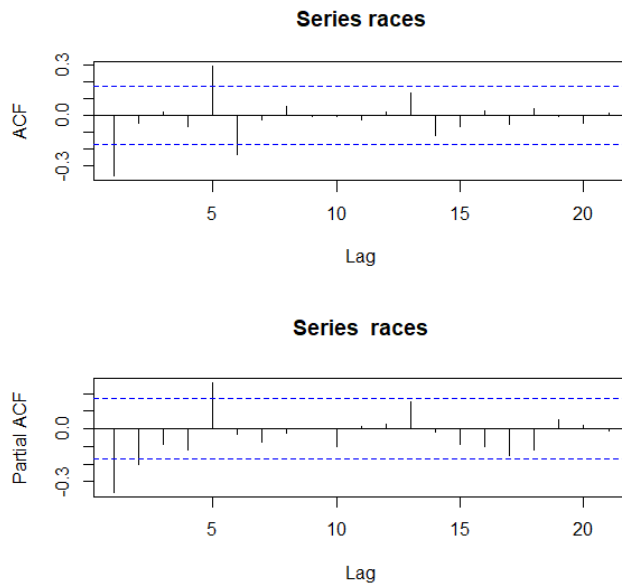
Plot deret waktu dari *return* ACES tampak lebih stasioner dibanding dengan harga penutupannya. Nilai p sebesar 0.01 juga memberikan kesimpulan bahwa data *return* telah stasioner. Sehingga selanjutnya kita dapat melakukan analisis deret waktu terhadap *return* tersebut.

Pemodelan Fungsi Rataan (*Mean Model*)

1. Plotting autokorelasi dan autokorelasi parsial dari *return* untuk mengidentifikasi model rata-rata.

```
> par(mfrow=c(2,1))
> acf(races)
> pacf(races)
```

Generalized Autoregressive Conditional Heteroskedasticity (GARCH)



Plot autokorelasi dan autokorelasi masing-masing menunjukkan *cut-off* sehingga model yang dapat dihasilkan adalah AR(p) atau MA(q). Berdasarkan lag yang keluar, maka model yang diidentifikasi adalah AR(2) dan MA(1).

2. Memilih model terbaik berdasarkan AIC terkecil.

```
> arima(races, order = c(2,0,0), method = "ML") #AR(2)
> arima(races, order = c(0,0,1), method = "ML") #MA(1)
```

Model	Normalitas	Ljung Box	Log-likelihood	AIC	BIC
AR(2)	1.241E-10	No autokorelasi	317.83	-629.66	-
MA(1)	4.363E-11	No autokorelasi	318.18	-632.35	-

Model yang dianggap terbaik memiliki AIC terkecil. AR(2) memiliki AIC yang lebih kecil dibandingkan MA(1) yakni sebesar -632.35 sehingga selanjutnya akan dilakukan diagnostik sisaan MA(1).


3. Menguji sisaan dari model yang telah ditentukan, yang difokuskan pada autokorelasi sisaan.

```
> sisa <- residuals(arima(races, order = c(0,0,1), method = "ML"))
> plot(sisa)
> shapiro.test(sisa)
```

```
Shapiro-Wilk normality test

data: sisa
W = 0.83954, p-value = 1.241e-10
```

```
> tsdiag(arima(races, order = c(0,0,1), method = "ML"), gof=16, omit.initiatif=F)
```




Berdasarkan diagram statistik Ljung-Box, model telah memenuhi asumsi no autokorelasi dilihat dari titik-titik sisaan yang berada di luar batas signifikansi. Namun berdasarkan tabel pada poin 2, didapatkan model MA(1) tidak memenuhi asumsi normalitas, karena nilai p sebesar $4.363E-11$ menyebabkan H_0 ditolak. Pada studi kasus ini asumsi normalitas diabaikan.

Pemodelan Fungsi (*Variance Model*)

1. Membuat plot autokorelasi dari komponen sisaan kuadrat untuk mendeteksi adanya korelasi ragam dari *return*.

```
> par(mfrow=c(2,1))
> acf(sisa^2)
> pacf(sisa^2)
```



Pada plot autokorelasi dan autokorelasi parsial dari sisaan kuadrat tersebut didapatkan masih ada lag yang signifikan berkorelasi sehingga dicurigai terdapat efek ARCH. Untuk lebih pasti, akan dilihat juga nilai Q Ljung-Box pada tingkat uji 5%.

```
> source("D:\\Tugas GARCH\\Note Sintaks\\lampiran.R")
```

```
> acfStat(sisa^2,36)
```

	ACF	PACF	Q-Stats	P-Value
0	0.195694515	1.0000000000	NA	NA
1	0.060892986	0.1956945149	5.132594	2.348061e-02
2	0.041472495	0.0234964720	5.633398	5.980304e-02
3	0.054753244	0.0262574399	5.867515	1.182369e-01
4	0.393929726	0.0422587177	6.278796	1.792726e-01
5	0.184260914	0.3894979579	27.736829	4.097379e-05
6	0.054654021	0.0501539236	32.469206	1.326275e-05
7	-0.001463234	-0.0131541381	32.888912	2.776820e-05
8	-0.007080321	-0.0391726563	32.889216	6.448406e-05
9	-0.017412589	-0.0178778664	32.896375	1.392147e-04
10	0.019332903	-0.1973849372	32.940033	2.787786e-04
11	-0.001360862	-0.0523404621	32.994300	5.272828e-04
12	0.040713185	-0.0233001318	32.994571	9.699078e-04
13	-0.040793615	-0.0233464357	33.239315	1.568540e-03

Berdasarkan statistik Ljung-Box dari sisaan kuadrat tersebut didapatkan autokorelasi serial hingga lag ke- m yang panjang (*long memory*) sehingga terindikasi terdapat efek GARCH.

*Generalized Autoregressive Conditional Heteroskedasticity
(GARCH)*

2. Pendugaan model GARCH. Umumnya pendugaan model ini diawali dengan GARCH(1,1) dan dapat dilakukan *overestimate* pada ordo (p,q) yang lebih tinggi. Model yang akan dicobakan adalah GARCH(1,1) dengan konstan, GARCH(1,1) tanpa konstan, MA(1)-GARCH(1,1) dengan konstan, dan MA(1)-GARCH(1,1) tanpa konstan.

```
> ## GARCH(1,1)
> fit <- garchFit(formula = ~garch(1,1), data = races, trace = F,
+               algorithm = "lbfgsb+nm")
> summary(fit)

> ## GARCH(1,1) >> tanpa mu
> fitm <- garchFit(formula = ~garch(1,1), data = races, trace = F,
+               algorithm = "lbfgsb+nm", include.mean = F)
> summary(fitm)

> ## MA(1)- GARCH(1,1)
> fit1 <- garchFit(formula = ~arma(0,1)+garch(1,1), data = races,
+               trace = F, algorithm = "lbfgsb+nm")
> summary(fit1)

> ## MA(1)- GARCH(1,1) >> tanpa mu
> fit2 <- garchFit(formula = ~arma(0,1)+garch(1,1), data = races,
+               trace = F, algorithm = "lbfgsb+nm", include.mean = F)
> summary(fit2)
```

3. Memilih model terbaik berdasarkan ringkasan statistik kriteria pemilihan model.

Model	LM Arch	No autokorelasi	Jarque-Bera	AIC	BIC
GARCH(1,1) c	0.9336118	Terpenuhi	0	-5.159012	-5.07122
GARCH(1,1)	0.9434867	Terpenuhi	0	-5.166972	-5.101128
MA(1)-GARCH(1,1) c	0.7851708	Terpenuhi	0	-5.190182	-5.080441
MA(1)-GARCH(1,1)	0.764065	Terpenuhi	0	-5.200818	-5.113025

Pada ringkasan beberapa model tersebut didapatkan model yang lebih baik dibanding lainnya adalah MA(1)-GARCH(1,1) tanpa konstan. Selanjutnya akan dilihat diagnostik sisaan dari model tersebut.

4. Pengujian diagnostik sisaan. Nilai-nilai dalam ringkasan diagnostik akan otomatis keluar saat menjalankan program. Berdasarkan ringkasan, model MA(1)-GARCH(1,1) tanpa konstan:
- Telah memenuhi tidak adanya efek ARCH/ GARCH dalam residual sampai lag ke- m dengan statistik LM sebesar -5.113025.
 - Telah memenuhi asumsi no autokorelasi, dimana semua nilai Q Ljung Box lebih dari taraf 5%.

Generalized Autoregressive Conditional Heteroskedasticity (GARCH)

Standardised Residuals Tests:				
			Statistic	p-Value
Jarque-Bera Test	R	Chi^2	96.85353	0
Shapiro-Wilk Test	R	W	0.9360205	1.029325e-05
Ljung-Box Test	R	Q(10)	5.738403	0.8367418
Ljung-Box Test	R	Q(15)	15.36072	0.4257597
Ljung-Box Test	R	Q(20)	18.66811	0.5434839
Ljung-Box Test	R^2	Q(10)	8.08011	0.621012
Ljung-Box Test	R^2	Q(15)	9.168485	0.8685443
Ljung-Box Test	R^2	Q(20)	11.40816	0.9349434
LM Arch Test	R	TR^2	8.265358	0.764065

- iii. Tidak memenuhi asumsi normalitas, dimana nilai Jarque Bera hanya sebesar 0.

5. Persamaan yang dapat dituliskan dari model heteroskedastisitas MA(1)-GARCH(1,1) adalah sebagai berikut:

Error Analysis:


	Estimate	Std. Error	t value	Pr(> t)
ma1	-3.391e-01	1.072e-01	-3.164	0.00156 **
omega	5.320e-05	1.829e-05	2.909	0.00363 **
alpha1	3.436e-01	1.218e-01	2.820	0.00480 **
beta1	5.667e-01	8.722e-02	6.498	8.16e-11 ***

- Model rata-rata: $return_t = \varepsilon_t - 3.391(E - 01)\varepsilon_{t-1}$
- Model ragam: $\sigma_t^2 = 5.32(E - 05) + 3.436(E - 01)\varepsilon_{t-1}^2 + 5.667(E - 01)\sigma_{t-1}^2$

6. Prediksi *return* dalam jangka waktu 5 hari ke depan dengan persamaan pada poin 4 adalah sebagai berikut:

```
> predict(fit2, n.ahead=5, plot=T) #default SK 95%
  meanForecast meanError standardDeviation lowerInterval upperInterval
1  0.003329546  0.01367325      0.01367325    -0.02346954    0.03012863
2  0.000000000  0.01564913      0.01494631    -0.03067174    0.03067174
3  0.000000000  0.01680037      0.01601744    -0.03292811    0.03292811
4  0.000000000  0.01778366      0.01693369    -0.03485533    0.03485533
5  0.000000000  0.01863370      0.01772663    -0.03652137    0.03652137
```

Prediction with confidence intervals



DAFTAR PUSTAKA

Rosadi D. 2011. *Analisis Ekonometrika & Runtun Waktu Terapan dengan R*. Kurniawan NW, editor. Yogyakarta (ID): Penerbit ANDI.

LAMPIRAN

Lampiran.R

```
acfStat <- function(x,lag=36)
{
  out1=acf(x,lag.max=lag,plot=F,na.action=na.pass)
  acfout=out1$acf
  out2=pacf(x,lag.max=lag,plot=F,na.action=na.pass)
  pacfout=NULL
  pacfout[1]=1
  pacfout=c(pacfout,out2$acf)
  temp1=NULL
  temp1[1]=NULL
  temp2=NULL
  temp2[1]=NULL
  for (i in 1:lag)
  {
    temp1[i+1]=Box.test(x,lag=i,type="Ljung")$statistic
    temp2[i+1]=Box.test(x,lag=i,type="Ljung")$p.value
  }
  result=cbind(ACF = acfout, PACF = pacfout, "Q-Stats" = temp1, "P-
Value" = temp2)
  rownames(result)= 0:lag
  # print(length(acfout))
  # print(length(pacfout))
  # print(length(temp1))
  # print(length(temp2))
  print(result)
}

arima.string <- function(object)
{
  order <- object$arma[c(1,6,2,3,7,4,5)]
  result <-
paste("ARIMA(",order[1],",",order[2],",",order[3],")",sep="")
  if(order[7]>1 & sum(order[4:6]) > 0)
    result <-
paste(result,"(",order[4],",",order[5],",",order[6],") [",order[7],"]",
sep="")
  if(is.element("constant",names(object$coef)) |
is.element("intercept",names(object$coef)))
    result <- paste(result,"with non-zero mean")
  else if(is.element("drift",names(object$coef)))
    result <- paste(result,"with drift")
  else if(order[2]==0 & order[5]==0)
    result <- paste(result,"with zero mean")
  else
    result <- paste(result,"")
  return(result)
}

printstatarima <- function (x, digits = 4,se=T,...){
  if (length(x$coef) > 0) {
    cat("\nCoefficients:\n")
    coef <- round(x$coef, digits = digits)
```

Generalized Autoregressive Conditional Heteroskedasticity (GARCH)

```
    if (se && nrow(x$var.coef)) {
      ses <- rep(0, length(coef))
      ses[x$mask] <- round(sqrt(diag(x$var.coef)), digits =
digits)
      coef <- matrix(coef, 1, dimnames = list(NULL,
names(coef)))
      coef <- rbind(coef, s.e. = ses)
      statt <- coef[1,]/ses
      pval <- 2*pt(abs(statt), df=length(x$residuals)-1,
lower.tail = F)
      coef <- rbind(coef,
t=round(statt,digits=digits),sign.=round(pval,digits=digits))
      coef <- t(coef)
    }
    print.default(coef, print.gap = 2)
  }
}
```


*Generalized Autoregressive Conditional Heteroskedasticity
(GARCH)*

Data

time	ACES	time	ACES	time	ACES	time	ACES	time	ACES	time	ACES	time	ACES
8/1/2018	25.1811	8/28/2018	25.9977	9/24/2018	25.7864	10/19/2018	24.1233	11/15/2018	23.9933	12/12/2018	24.6721	1/8/2019	23.7135
8/2/2018	25.4441	8/29/2018	26.1258	9/25/2018	25.5711	10/22/2018	24.0826	11/16/2018	24.5292	12/13/2018	24.6701	1/9/2019	24.0291
8/3/2018	25.4520	8/30/2018	26.0077	9/26/2018	25.4689	10/23/2018	23.8733	11/19/2018	24.3456	12/14/2018	24.2027	1/10/2019	24.3706
8/6/2018	25.6356	8/31/2018	26.0374	9/27/2018	25.4123	10/24/2018	23.6788	11/20/2018	23.8346	12/17/2018	23.3305	1/11/2019	24.3626
8/7/2018	25.7100	9/3/2018	24.6592	9/28/2018	25.5314	10/25/2018	23.7750	11/21/2018	24.0330	12/18/2018	23.1757	1/14/2019	24.0829
8/8/2018	25.8092	9/4/2018	25.9184	10/1/2018	25.5810	10/26/2018	23.5964	11/22/2018	24.6592	12/19/2018	22.8344	1/15/2019	24.1336
8/9/2018	25.8102	9/5/2018	25.8489	10/2/2018	25.7695	10/29/2018	23.2789	11/23/2018	24.1729	12/20/2018	22.2679	1/16/2019	24.3397
8/10/2018	25.7298	9/6/2018	25.6703	10/3/2018	25.5423	10/30/2018	23.8048	11/26/2018	24.5371	12/21/2018	21.9134	1/17/2019	24.5757
8/13/2018	25.7695	9/7/2018	25.4966	10/4/2018	24.8070	10/31/2018	24.0826	11/27/2018	24.7971	12/24/2018	21.2663	1/18/2019	24.5687
8/14/2018	25.7695	9/10/2018	25.5939	10/5/2018	24.4796	11/1/2018	24.1918	11/28/2018	24.7971	12/25/2018	24.6592	1/21/2019	24.6592
8/15/2018	25.1742	9/11/2018	25.6306	10/8/2018	24.4399	11/2/2018	24.1640	11/29/2018	25.0918	12/26/2018	22.2698	1/22/2019	24.1386
8/16/2018	25.4619	9/12/2018	25.9968	10/9/2018	24.4399	11/5/2018	24.5887	11/30/2018	25.0650	12/27/2018	22.2151	1/23/2019	24.1635
8/17/2018	25.4024	9/13/2018	26.0275	10/10/2018	24.2017	11/6/2018	24.4597	12/3/2018	25.3032	12/28/2018	22.5606	1/24/2019	24.5797
8/20/2018	25.7576	9/14/2018	25.8787	10/11/2018	23.3950	11/7/2018	24.4597	12/4/2018	25.1097	12/31/2018	22.6054	1/25/2019	24.9152
8/21/2018	26.1962	9/17/2018	25.7695	10/12/2018	23.4377	11/8/2018	24.7078	12/5/2018	24.6592	1/1/2019	24.6592	1/28/2019	24.7738
8/22/2018	26.2855	9/18/2018	25.8936	10/15/2018	23.9338	11/9/2018	24.7078	12/6/2018	24.9559	1/2/2019	22.6890	1/29/2019	24.7877
8/23/2018	26.2260	9/19/2018	25.8489	10/16/2018	23.9338	11/12/2018	24.4101	12/7/2018	24.5510	1/3/2019	22.4192	1/30/2019	24.9650
8/24/2018	26.1813	9/20/2018	26.0424	10/17/2018	24.4200	11/13/2018	24.1521	12/10/2018	24.5579	1/4/2019	23.1161	1/31/2019	24.6592
8/27/2018	26.6923	9/21/2018	26.1962	10/18/2018	24.2017	11/14/2018	23.8544	12/11/2018	24.5321	1/7/2019	23.4706		